

# Obliczanie norm i współczynników uwarunkowania macierzy

Jakub Płowiec, Filip Dziurdzia

## Zadanie

W wybranym języku programowania (Python) napisać program, który:

- Oblicza normę macierzową  $\|M\|_1$
- Oblicza współczynnik uwarunkowania macierzowy  $\kappa_1(M)$
- Oblicza normę macierzową  $\|M\|_2$
- Oblicza współczynnik uwarunkowania macierzowy  $\kappa_2(M)$
- Oblicza normę macierzową  $\|M\|_p$
- Oblicza współczynnik uwarunkowania macierzowy  $\kappa_p(M)$
- Oblicza normę macierzową  $\|M\|_\infty$
- Oblicza współczynnik uwarunkowania macierzowy  $\kappa_\infty(M)$

## Wstęp teoretyczny

### 1. Normy macierzowe

Norma macierzowa to funkcja przypisująca każdej macierzy nieujemną liczbę rzeczywistą, która opisuje jej "wielkość". Wyróżniamy m.in.:

- **Norma kolumnowa ( $\|M\|_1$ ):** maksymalna suma bezwzględnych wartości elementów w kolumnie.
- **Norma spektralna ( $\|M\|_2$ ):** największa wartość singularna macierzy (czyli pierwiastek z największej wartości własnej  $M^T M$ ).
- **Norma Frobeniusa ( $\|M\|_F$ ):** pierwiastek z sumy kwadratów wszystkich elementów macierzy.

- **Norma wierszowa** ( $\|M\|_{\infty}$ ): maksymalna suma bezwzględnych wartości elementów w wierszu.

## 2. Współczynnik uwarunkowania

Współczynnik uwarunkowania macierzy względem danej normy to liczba:

$$\kappa_p = \|M\|_p \cdot \|M^{-1}\|_p$$

$$\kappa_p = \|M\|_p \cdot \|M^{-1}\|_p$$

Im wyższy współczynnik, tym bardziej układ równań oparty na tej macierzy jest **wrażliwy na zakłócenia** (czyli jest źle uwarunkowany). Wartości bliskie 1 oznaczają dobrze uwarunkowaną macierz.

## Rozwiązanie

Implementacja została wykonana w języku **Python**. Biblioteka `numpy` została wykorzystana do obliczenia wartości własnych macierzy oraz jako benchmark.

## Rozwiązanie

**Funkcja:** `norm_1(M: array) -> float`

**Dane wejściowe:**

- `M` : macierz

**Wyniki:**

- wartość normy macierzowej  $\|M\|_1$

**Implementacja:**

```
def norm_1(M):
    return max(sum(abs(M[i][j]) for i in range(len(M))) for j in range(len(M[0])))
```

## Funkcja: norm\_2(M: array) -> float

### Dane wejściowe:

- M : macierz

### Wyniki:

- wartość normy macierzowej  $\|M\|_2$

### Implementacja:

```
def norm_2(M):  
    MtM = np.dot(np.transpose(M), M)  
    eigenvalues = np.linalg.eigvals(MtM)  
    max_eigenvalue = max(abs(eig) for eig in eigenvalues)  
    return max_eigenvalue ** 0.5
```

## Funkcja: norm\_frobenius(M: array) -> float

### Dane wejściowe:

- M : macierz

### Wyniki:

- wartość normy macierzowej Frobeniusa  $\|M\|_F$

### Implementacja:

```
def norm_frobenius(M):  
    return (sum(M[i][j]**2 for i in range(len(M)) for j in range(len(M[0]))))**0.5
```

## Funkcja: norm\_inf(M: array) -> float

### Dane wejściowe:

- M : macierz

### Wyniki:

- wartość normy macierzowej  $\|M\|_{\infty}$

### Implementacja:

```
def norm_inf(M):  
    return max(sum(abs(M[i][j]) for j in range(len(M[0]))) for i in range(len(M)))
```

### Funkcja:

**test\_implementation(matrix\_size: int) -> None | AssertionError**

### Dane wejściowe:

- `matrix_size` : rozmiar macierzy kwadratowej która ma zostać wygenerowana
- `epsilon` : dozwolony błąd podczas porównania wyników z biblioteką `numpy`

### Wyniki:

- Zapewnienie zgodnych wyników pomiędzy implementacjami lub błąd

### Funkcja: **benchmark\_and\_plot(matrix\_size: int) -> None**

### Dane wejściowe:

- `matrix_size` : rozmiar macierzy kwadratowej która ma zostać wygenerowana

### Wyniki:

- Wykresy porównujące naszą implementację z implementacjami w bibliotece `numpy`

## Wyniki

Wygenerowaliśmy macierze kwadratowe o rozmiarze `1000` i korzystając z funkcji `benchmark_and_plot` porównaliśmy czasy wykonania naszych implementacji oraz implementacji w bibliotece `numpy` oraz przedstawiliśmy te różnice na wykresie:

